

平成27年度  
卒業論文

題目

着席状態での動作に基づいた  
ソフトバイオメトリクス認証  
Soft biometrics authentication  
based on a motion in the seated state

B5研究室 4年 梅林 雄大

平成28年2月22日

# 目次

<b>第1章</b>	<b>序論</b>	<b>1</b>
1.1	背景と目的 . . . . .	1
1.2	論文構成 . . . . .	2
<b>第2章</b>	<b>骨格情報</b>	<b>3</b>
2.1	Kinect の概要 . . . . .	3
2.2	骨格情報の取得 . . . . .	4
<b>第3章</b>	<b>提案手法</b>	<b>5</b>
3.1	提案手法の概要 . . . . .	5
3.2	提案手法の流れ . . . . .	5
<b>第4章</b>	<b>識別器</b>	<b>7</b>
4.1	サポートベクタマシンの概要 . . . . .	7
4.2	線形クラス分類 . . . . .	7
4.3	マージン最大化 . . . . .	9
4.4	サポートベクタ . . . . .	10
4.5	ソフトマージン . . . . .	11
4.6	カーネルトリック . . . . .	13
<b>第5章</b>	<b>評価実験</b>	<b>16</b>
5.1	実験目的 . . . . .	16
5.2	実験条件 . . . . .	16
<b>第6章</b>	<b>結論</b>	<b>17</b>
	謝辞	18
	参考文献	19

## 図 目 次

2.1	Kinect . . . . .	3
2.2	SDK で取得可能な関節点 . . . . .	4
3.1	提案手法の流れ . . . . .	6
3.2	骨格座標系 . . . . .	6
4.1	線形しきい素子 . . . . .	8
4.2	2次元サンプルにおける入力特徴と識別平面 . . . . .	8
4.3	2次元サンプルにおけるマージン . . . . .	9
4.4	サポートベクタの例 . . . . .	10
4.5	ソフトマージンの例 . . . . .	11
4.6	高次元特徴空間への変換の例 . . . . .	13
4.7	ガウス関数 . . . . .	14
4.8	シグモイド関数 . . . . .	15

# 表 目 次

# 第 1 章 序論

## 1.1 背景と目的

近年，日常生活の中での手続きの多くがコンピュータにより行われている．人の負担を軽減するために，時代に応じたシステムが構築されている．セキュリティ分野においても様々な場所でコンピュータによる個人認証が行われており，個人認証技術の発達が進んでいる．現在利用されている個人認証システムは，パスワードや IC カードを使用したものが多く見られる．しかし，これらは，パスワードの流出，カードの盗難などにより偽装が比較的容易である．また，複雑なパスワードを設定してしまうと利用者の負担も大きくなる．そこで現在，多く用いられている個人認証システムとして，バイオメトリクス認証がある．バイオメトリクス認証とは，指紋，虹彩，顔，座り方，歩き方など個人の特徴をもとに認証を行うシステムである．しかし，指紋や虹彩による認証は，特別な機器や動作を必要とするため，不便である．一方，顔を用いた認証は特別な機器や動作を必要としない．しかし，周囲の環境の変化により，認証の精度が低下してしまう問題点がある．

そこで，本研究では，顔などの身体的特徴による個人認証 (バイオメトリクス) ではなく，人間の動作を用いる動作的特徴による個人認証 (ソフトバイオメトリクス) に注目した．人間の動作は人によって異なった癖があり，それにより個人認証ができるのではないかと考えた．さらに，動作的特徴を用いた認証は，先に述べた身体的特徴と組み合わせて利用することも可能である．柔軟な応用が可能な点も大きな利点であると考え．実際に，歩き方により個人を認証する技術 [1] は開発されており，顔が映らない状態でも，高確率で人物を特定することが可能になっている．本論文では，座り方による個人認証を目的とする．パソコンを使用するときには座った状態が多いので，座り方での個人認証が有効であると考え．

本論文では，骨格情報を用いた個人認証システムを提案し，骨格情報の取得には Microsoft 社の Kinect を用いて 20 箇所の関節情報を取得し，身体的特徴を抽出する．特徴抽出後，サポートベクタマシン (Support Vector Machine : SVM) を用いて，さまざまな学習方法の比較実験を行う．そして，本人と本人以外の 2 クラスに分類を行い，ソフトバイオメトリクスへの応用可能性について検討する．

## 1.2 論文構成

本論文は全6章で構成されている。第1章では背景と目的について述べた。第2章では骨格情報について、第3章ではSVMについて、第4章では提案手法について述べる。第5章では実験の結果、および考察を述べ、第6章において結論を述べる。

## 第 2 章 骨格情報

本研究では，Kinect を用いて骨格情報の取得を行った．本章では，Kinect と骨格情報について詳しく述べて行く．

### 2.1 Kinect の概要

Kinect は，Microsoft 社が開発した Xbox360 用のコントローラの一つである．ハードウェア機能として，RGB カメラ，距離カメラ，4つのマイクを並べたマイクアレイがある．その中でも，距離カメラは，Kinect から赤外線を照射し，その反射を読み取ることで利用者を認識し，骨格の情報を認識することができる．骨格を認識，追跡することにより，利用者の動きを 3次元データで取得することが可能である．Kinect を骨格の認識，追跡をするために設置するときは，高さ 60cm から 180cm の間に設置し，利用者の全身がカメラに収まるようにする．Kinect の垂直視野角は 43 度，水平視野角は 57 度である．実際に使用する際は，頭から膝上のあたりまでが画面に入れば認識されるが，全身が画面に入ったほうがより精度が向上する．図 2.1 は実際に使用した Kinect と同じ種類のものである．



図 2.1 Kinect

## 2.2 骨格情報の取得

Kinect を使用して骨格情報を取得する．Microsoft 社が公開したソフトウェア開発キットである Kinect for Windows SDK (以下 SDK)[2] を用いることにより，音声を含めて Kinect に搭載されている各種センサのデータを取得することができる．また，SDK は骨格座標の取得が可能であり，図 2.2 のように，体の中心線上の 4 箇所と，両手足の関節位置 16 箇所の合計 20 箇所が取得できる．骨格座標は 3 次元データの位置情報をメートル単位で取得でき，30fps で計測される．分解能は，x 成分，y 成分が 2m の場所で 3mm，z 成分が 1cm である．Kinect で取得した骨格座標をもとに分析を行っていく．




図 2.2 SDK で取得可能な関節点



## 第 3 章 提案手法

本章では，座り方による個人認証を行うための手法について詳しく述べる．

### 3.1 提案手法の概要

本研究では，本人と本人以外の 2 クラスに分類することを目的としている．そのため，2 クラスのパターン認識において高い認証性能を持つ SVM を用いる．

Kinect を用いて関節位置の 3 次元座標を取得し，前処理，特徴抽出を行った後，SVM を使用して 2 クラスに分類し認証を行う．

また，未学習データに対する性能を向上させるための工夫がされていることも SVM を用いる理由である．以下では，それぞれの処理の流れについて詳しく述べる．

### 3.2 提案手法の流れ

提案手法の流れを図 3.1 に示す．まず，Kinect を用いて骨格情報を取得する．次に，前処理として，Kinect から取得した 3 次元座標を相対座標に変換する．骨格座標の座標軸は，図 3.2 に示すように，Kinect の赤外線カメラを中心に右手座標系である．つまり，赤外線カメラの位置を原点としている．そのため，初期位置に多少のずれがある場合，正確な特徴抽出を行うことが難しい．そこで，前処理として背骨の座標を原点とした相対座標への変換を行う．全ての関節位置の座標から背骨の座標を引くことにより相対座標へ変換する．これにより，初期位置のずれに頑健になり，より正確な骨格の特徴を取得することが可能になる．

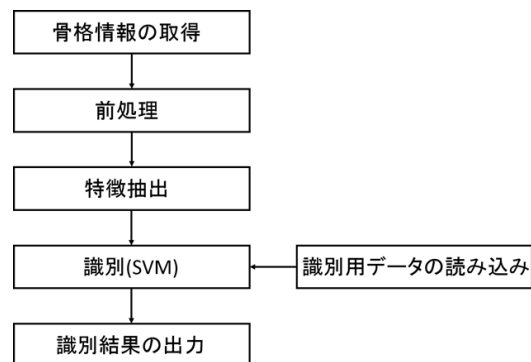


図 3.1 提案手法の流れ




図 3.2 骨格座標系

前処理を行った座標を，0.5 秒ごとに平均を計算することで特徴抽出を行う．座る動作には，歩く動作など複数の動作が合わさることが多い．また，人それぞれ座る速度も異なる．一定時間で分割することで，そういった特徴をより多く抽出することが可能になる．そして，得られた特徴から SVM を用いて識別を行い，認証結果を出力する．

## 第 4 章 識別器

### 4.1 サポートベクタマシンの概要

サポートベクタマシン (Support Vector Machine : SVM) は教師あり学習を用いるパターン認識モデルの一つ [3] である。主にパターン認識や回帰分析に適用されることが多い。SVM は、基本的には線形しきい素子を用いて、2 クラスのパターン識別器を構成する手法である。そのため、文字認識などの多クラスの識別器を構成する場合には、複数の SVM を組み合わせる必要がある。また、あらかじめ与えられたデータを分類するだけでなく、未学習データに対して高い識別性能を得ることができるという特徴がある。一般的にはクラス分類において、データの次元数が多いとデータの分類性能は悪くなるが、SVM では、データの次元数が多くても性能低下が少ない。カーネル法を用いることにより、非線形の識別関数を構成できるように拡張することも可能である。

このように、SVM は現在知られている多くの手法の中でも 2 クラスのパターン認識においては、最も認識性能の優れた学習方法の一つであり、様々な応用問題を解決できる可能性を持っている。

### 4.2 線形クラス分類

SVM は、ニューラルネットワークに使用されているパーセプトロンと基本構造が同じ分類器である。そのパーセプトロンの中でも最も単純な線形しきい素子を用いて、2 クラスのパターン識別器を構成する。線形しきい素子は、図 4.1 に示すようなニューロンを単純化したモデルであり、入力特徴ベクトル  $\mathbf{x}$  に対して、式 (4.1) の識別関数 (線形識別関数) により、2 値の出力値を計算する。




図 4.1 線形しきい素子

$$f(x) = \sin\{(w \cdot x) + b\} \quad (4.1)$$

ここで、 $w$  はシナプス荷重に対応するパラメータであり、しきい値である。とによって関数は制御されるため、学習によって求めるべきパラメータである。また、関数  $\sin(u)$  は 1 もしくは -1 を出力する符号関数である。

$$\sin(u) = \begin{cases} 1 & (u \geq 0) \\ -1 & (u \leq 0) \end{cases} \quad (4.2)$$

このモデル、入力特徴ベクトル とシナプス荷重 の内積が閾値を超えていれば 1 を、越えなければ -1 を出力する。これは、幾何学的には、識別平面により、入力特徴空間  $X$  を 2 つに分ける識別平面を意味し、この識別平面は  $(w \cdot x) + b = 0$  より定義される。

2次元空間における入力特徴と識別平面を図 4.2 に示す。




図 4.2 2次元サンプルにおける入力特徴と識別平面

### 4.3 マージン最大化

線形しきい素子を用いて、線形分離が可能な訓練サンプル集合  $S$  について考える。この訓練サンプル集合  $S$  は、線形しきい素子のパラメータをうまく調節することにより、訓練サンプル集合を誤りなく分けることが可能である。しかし、訓練サンプル集合が線形分離可能であるとしても、一般には、訓練サンプル集合を誤りなく分けるパラメータを一意に定めるのは難しい。

SVM では、このパラメータを求める手法としてマージン最大化と呼ばれる方法を使用する。マージン最大化とは、最も近い訓練サンプルとの距離をマージンと定義し、マージンが最大になるような識別平面を求める手法である。訓練サンプルをすれすれに通るのではなく、なるべく余裕を持って分離することが可能な識別平面を求めることができる。この2次元訓練サンプル集合におけるマージンを図 4.3 に示す。




図 4.3 2次元サンプルにおけるマージン

$N$  個の特徴ベクトル  $x_1, x_2, \dots, x_{N-1}, x_N$  と、それぞれのサンプルに対する正解のクラスラベル  $t_1, t_2, \dots, t_{N-1}, t_N$  を持った、訓練サンプル集合  $S$  において、 $S$  が線形分離可能な場合には、以下の式 (4.3) を満たすパラメータが存在する。

$$t_i(w_i x_i + b) \geq 1 (i = 1, 2, \dots, N - 1, N) \quad (4.3)$$

これは、図 4.3 上の2つの点線  $((w \cdot x) + b = \pm 1)$  で定義される2つの超平面より、全ての訓練サンプルが完全に分離しており、2つの超平面の内側にはサンプルが1つも存在しないことを意味している。このとき、識別平面とこの2つの超平面との距離(マージンの大きさ)は、 $\frac{1}{\|w\|}$  と表現される。

つまり，マージン最大化を満たすパラメータ，を求める問題は，以下の式 (4.4) に示す，目的関数  $L(w)$  を最小化する問題として考えることができる．

$$L(w) = \frac{1}{2} \|w\|^2 \quad (4.4)$$

この目的関数の最適化問題は，数理計画法の分野において2次計画問題に帰着することができる．そのため最適解が1つに定まるようになる．その結果，分類問題における問題の1つである局所的最適解に陥ることがなくなることがわかる．

#### 4.4 サポートベクタ

SVMでは，訓練の際に分離平面を構成する特徴ベクトルを選び出し，サポートベクタとする．これにより，計算量の削減を行うことができる．これは訓練が完了した段階に，識別平面を構成するために必要なマージンの小さい特徴ベクトルを最小限の数だけ確保することにより実現する．この特徴ベクトルをサポートベクタと呼ぶ．分類の段階において，識別平面を構成するときには，このサポートベクタとそれに伴うパラメータのみを使用する．図4.4では，2つの超平面に接している点Aがサポートベクタである．




図 4.4 サポートベクタの例

## 4.5 ソフトマージン

前節までは、線形分離が可能な訓練サンプル集合を例に挙げて SVM の概要、識別、学習方法について述べた。しかしながら、パターン認識の実問題で線形分離可能な場合は少ない。故に、実際的な問題に SVM を使用するには、工夫が必要である。そこで、完全な線形分離ができなくても、多少の識別誤りを許容するように制約を緩め、最適な識別平面を求める方法である、ソフトマージンについて説明する。

マージン最大化では、式 (4.3) を制約条件としている。この場合には、2つの超平面によってデータを完全に分離することが可能なため、2つの超平面の間にデータは存在しない。ソフトマージンでは、いくつかのデータが超平面を超えて、超平面の内側に入ることを許容する。図 4.5 で示されるように、識別平面を超えた位置にデータが存在する場合を想定している。これにより、ノイズや誤りによって線形分離が不可能な入力データに対しても識別平面を構成することが可能になる。




図 4.5 ソフトマージンの例

ノイズや誤りによって、誤った領域に存在している訓練サンプルの識別平面からの距離を、誤り量のパラメータ  $\varepsilon_i (\geq 0)$  を用いて、 $\frac{\varepsilon_i}{\|w\|}$  と表すと、誤ったサンプルの総和は式 (4.5) のようになる。

$$\sum_{i=1}^N \frac{\varepsilon_i}{\|w\|} \quad (4.5)$$

となる。式 (4.5) は誤り量なので、なるべく小さい値となることが望ましい。このとき、誤り量のパラメータ  $\varepsilon_i$  を用いて、最適な識別面を求める制約条件は式 (4.6) となる。

$$\varepsilon_i (\geq 0), t_i(w_i x_i + b) \geq 1 - \varepsilon_i (i = 1, 2, \dots, N - 1, N) \quad (4.6)$$

この条件の下で、式 (4.7) で示す目的関数  $L(w, \varepsilon)$  を最小化すればよい。

$$L(w, \varepsilon) = \frac{1}{2} \|w\|^2 + \gamma \sum_{i=1}^N \varepsilon_i \quad (4.7)$$

この目的関数では、パラメータ  $\gamma$  を用いて、第1項の-marginの大きさと、第2項の誤り距離の優先比率の調整を行う。



## 4.6 カーネルトリック

前節のソフトマージンを用いることで、線形分離可能でない場合に対して、線形しきい素子のパラメータを求めることが可能である。しかし、本質的に非線形で複雑な識別問題への適用は不可能である。非線形問題に対応するための方法として、カーネルトリック [4] を使用する。特徴ベクトルを非線形変換して線形識別をしやすい高次元特徴空間に写像し、線形識別を行う。写像した先で線形識別を行うことは、もとの空間で識別関数を構成することに対応する。図 4.6 は特徴ベクトル  $x$  を写像  $\phi(x)$  によって変換し、線形分離しやすくした例である。




図 4.6 高次元特徴空間への変換の例

しかし、高次元への写像を行うと次元の増加に伴い汎化能力が落ちてしまう。また、難しい問題を線形分離可能にするためには、訓練サンプルと同程度の大きな次元に写像しなければならない。そのため、膨大な計算量が必要になる。そこでカーネルトリックの利用を考える。

SVM では、識別関数が入力パターンの内積のみに依存しており、内積を計算すれば最適な識別関数を構成することが可能である。高次元空間での 2 つの要素  $\phi(x_1)$  と  $\phi(x_2)$  の内積を式 (4.8) と定義する。

$$\phi(x_1) \cdot \phi(x_2) = K(x_1, x_2) \quad (4.8)$$

非線形写像によって変換された高次元空間での特徴  $\phi(x_1)$  や  $\phi(x_2)$  の計算する代わりに、 $K(x_1, x_2)$  から最適な非線形写像を構成できる。このような  $K$  のことをカーネルと呼ぶ。このように高次元に写像しながら、実際には写像された高次元空間上での特徴の計算を避け、カーネルの計算のみで最適な識別関数を構成する。この一連の操作がカーネルトリックである。実用的には、は計算が容易なものが望ましい。

カーネルトリックを利用して，高次元空間に射影したときの線形分離の制約条件は，式 (4.9)，式 (4.10) に示す．

$$t_i(\phi(w_i) \cdot \phi(x_i) + b) \geq 1, (i = 1, 2, \dots, N - 1, N) \quad (4.9)$$

$$t_i(K(w_i, x_i) + b) \geq 1, (i = 1, 2, \dots, N - 1, N) \quad (4.10)$$

写像空間はカーネル  $K$  の種類によって異なるため，分離しやすい高次元空間上に射影が行われるようにカーネル  $K$  を選択しなければならない．ここでは，代表的なカーネルを3つ以下に示す．

#### ●多項式カーネル

定数  $c > 0$ ，次数を  $d$  とする多項式カーネルを式 (4.11) に示す．

$$K(x_i, x_j) = (x_i \cdot x_j + c)^d \quad (4.11)$$

#### ●ガウシアンカーネル

データに関する事前知識がない場合に用いられる汎用的なカーネルである． $\sigma^2$  ( $\sigma > 0$ ) は分散を示す．

$$K(x_i, x_j) = \exp\left(-\frac{\|x_i - x_j\|^2}{2\sigma^2}\right) \quad (4.12)$$




図 4.7 ガウス関数

●シグモイドカーネル主に、ニューラルネットワークの代わりに使用されるシグモイドカーネルを用いることにより、SVM とニューラルネットワークが表層的に類似したものになるためである。

$$K(x_i, x_j) = \tanh(cx_i \cdot x_j + \theta) \quad (4.13)$$




図 4.8 シグモイド関数

## 第 5 章 評価実験

本章では,

### 5.1 実験目的

### 5.2 実験条件

## 第 6 章 結論

結論をしっかりとく

## 謝辞

本研究を進めるにあたり，絶えず御指導，御教授くださいました福見稔教授，柏原考爾准教授，伊藤桃代助教，伊藤伸一助教に深く感謝すると共に厚く御礼申し上げます。また，貴重な御意見，提案を頂いた B5 研究室の皆様に深く感謝いたします。

## 参考文献

- [1] 真部雄介, 菅原研次, “RGB カメラと深度センサーで計測した人間の動作時系列に基づくバイオメトリスク照合”, 第1回バイオメトリクス研究会